



中国高科集团
CHINA HI-TECH GROUP

Logistic回归

乐·教育 | 智·全球

Embrace education | Enlighten horizon

2021年12月




回顾

- KNN
 - 决策树
 - 贝叶斯分类器
 - 是否有一种算法
 - 二分类、多类
 - 输出连续值
 - 预测
 - 优化算法
- 回归



回归

面积 (m ²)	销售价钱 (万元)
123	250
150	320
87	160
102	220
...	...



$$h(x) = h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2$$



回归

- 回归：广义线性模型 (generalized linear model)
- 分类：根据因变量的不同
 - 连续：多重线性回归
 - 二项分布：logistic回归
 - poisson分布：poisson回归
 - 负二项分布：负二项回归

逻辑斯蒂分布

- Logistic distribution
- 设X是连续随机变量，X服从Logistic distribution,

- 分布函数:
$$F(x) = P(X \leq x) = \frac{1}{1 + e^{-(x-\mu)/\gamma}}$$

- 密度函数:
$$f(x) = F'(x) = \frac{e^{-(x-\mu)/\gamma}}{\gamma(1 + e^{-(x-\mu)/\gamma})^2}$$

- μ 为位置参数, γ 大于0为形状参数,
($\mu, 1/2$)中心对称


$$F(-x + \mu) - \frac{1}{2} = -F(x - \mu) + \frac{1}{2}$$



- Sigmoid:

$$f(z) = \frac{1}{1 + \exp(-z)}$$

$$f'(z) = f(z)(1 - f(z))$$




$[0, 1]$


- 双曲正切函数 (tanh)

$$f(z) = \tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$$

$$f'(z) = 1 - (f(z))^2$$



$[-1, 1]$



Sigmoid function:

$$h_{W,b}(x) = f(W^T x) = f(\sum_{i=1}^3 W_i x_i + b), \quad f(z) = \frac{1}{1 + \exp(-z)}.$$

```
def sigmoid(inX):  
    return 1.0/(1+exp(-inX))
```

二项逻辑斯蒂回归

- Binomial logistic regression model
 - 由条件概率 $P(Y|X)$ 表示的分类模型
 - 形式化为logistic distribution
 - X 取实数, Y 取值1,0

$$P(Y=1|x) = \frac{\exp(w \cdot x + b)}{1 + \exp(w \cdot x + b)}$$
$$P(Y=0|x) = \frac{1}{1 + \exp(w \cdot x + b)}$$



$$P(Y=1|x) = \frac{\exp(w \cdot x)}{1 + \exp(w \cdot x)}$$
$$P(Y=0|x) = \frac{1}{1 + \exp(w \cdot x)}$$

$$w = (w^{(1)}, w^{(2)}, \dots, w^{(n)}, b)^T$$

$$x = (x^{(1)}, x^{(2)}, \dots, x^{(n)}, 1)^T$$



二项逻辑斯蒂回归

- 事件的几率odds: 事件发生与事件不发生的概率之比为

$$\frac{p}{1-p}$$

- 称为事件的发生比(the odds of experiencing an event),
- 对数几率:

$$\text{logit}(p) = \log \frac{p}{1-p}$$

- 对逻辑斯蒂回归:

$$\log \frac{P(Y=1|x)}{1-P(Y=1|x)} = w \cdot x$$



似然函数

- *logistic*分类器是由一组权值系数组成的，最关键的问题就是如何获取这组权值，通过极大似然函数估计获得，并且 $Y \sim f(x; w)$
- 似然函数是统计模型中参数的函数。给定输出 x 时，关于参数 θ 的似然函数 $L(\theta|x)$ （在数值上）等于给定参数 θ 后变量 X 的概率：
 $L(\theta|x) = P(X=x|\theta)$
- 似然函数的重要性不是它的取值，而是当参数变化时概率密度函数到底是变大还是变小。
- 极大似然函数：似然函数取得最大值表示相应的参数能够使得统计模型最为合理



似然函数

- 那么对于上述 m 个观测事件， 设

$$P(Y=1|x)=\pi(x), \quad P(Y=0|x)=1-\pi(x)$$

- 其联合概率密度函数， 即似然函数为：

$$\prod_{i=1}^N [\pi(x_i)]^{y_i} [1-\pi(x_i)]^{1-y_i}$$

- 目标： 求出使这一似然函数的值最大的参数估，
 w_1, w_2, \dots, w_n ， 使得 $L(w)$ 取得 最大值。
- 对 $L(w)$ 取对数：



模型参数估计

- 对数似然函数

$$\begin{aligned} L(w) &= \sum_{i=1}^N [y_i \log \pi(x_i) + (1 - y_i) \log(1 - \pi(x_i))] \\ &= \sum_{i=1}^N \left[y_i \log \frac{\pi(x_i)}{1 - \pi(x_i)} + \log(1 - \pi(x_i)) \right] \\ &= \sum_{i=1}^N [y_i (w \cdot x_i) - \log(1 + \exp(w \cdot x_i))] \end{aligned}$$

- 对 $L(w)$ 求极大值，得到 w 的估计值。
- 通常采用梯度下降法及拟牛顿法，学到的模型：

$$P(Y = 1 | x) = \frac{\exp(\hat{w} \cdot x)}{1 + \exp(\hat{w} \cdot x)} \quad P(Y = 0 | x) = \frac{1}{1 + \exp(\hat{w} \cdot x)}$$



多项logistic回归

- 设Y的取值集合为

$$\{1, 2, \dots, K\}$$

- 多项logistic回归模型

$$P(Y = k | x) = \frac{\exp(w_k \cdot x)}{1 + \sum_{k=1}^{K-1} \exp(w_k \cdot x)}, \quad k = 1, 2, \dots, K-1$$

$$P(Y = K | x) = \frac{1}{1 + \sum_{k=1}^{K-1} \exp(w_k \cdot x)}$$